

Микросервисы: масштабирование

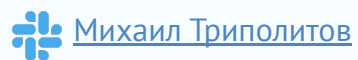


Михаил
Триполитов



Михаил Триполитов

Technical Lead





План занятия

1. [Scale Cube](#)
2. [Балансировка](#)
3. [Кэширование](#)
4. [Автомасштабирование](#)
5. [Service Discovery](#)
6. [Service Mesh](#)
7. [Итоги](#)
8. [Домашнее задание](#)



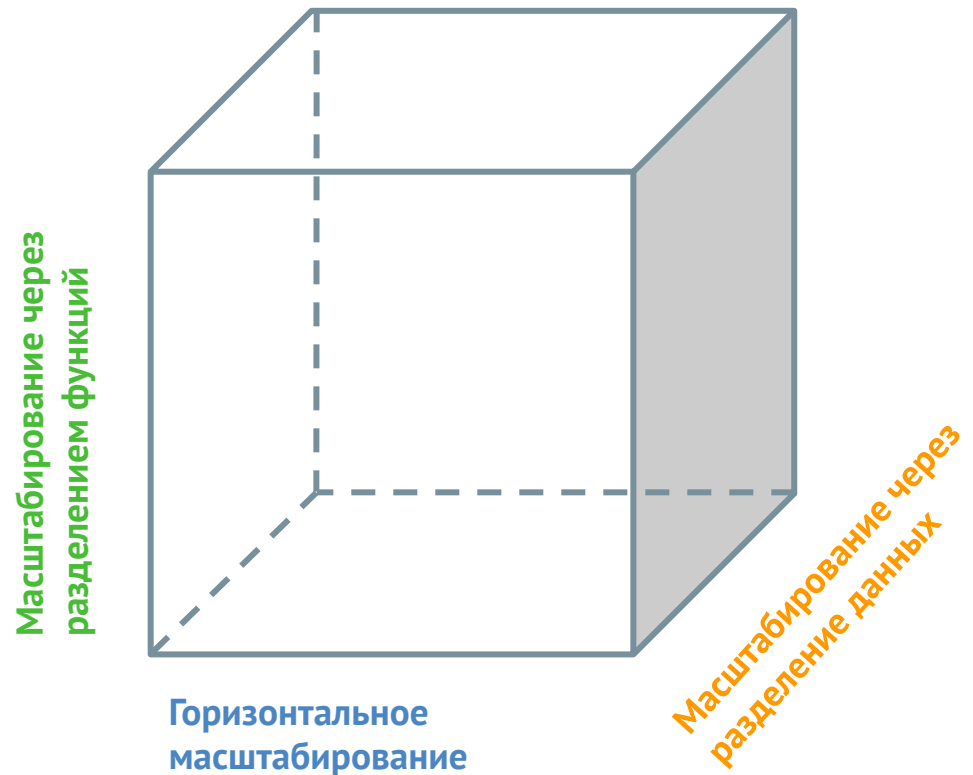
Scale Cube

Scale Cube

Ось X - горизонтальное масштабирование: запуск нескольких копий приложения

Ось Y - масштабирование разделением приложения: функции выделяются в отдельные сервисы и запускают независимо друг от друга

Ось Z - масштабирование через разделение данных: каждая запущенная копия сервиса отвечает за своё подмножество данных





Хрупкость системы

Способы защиты от хрупкости

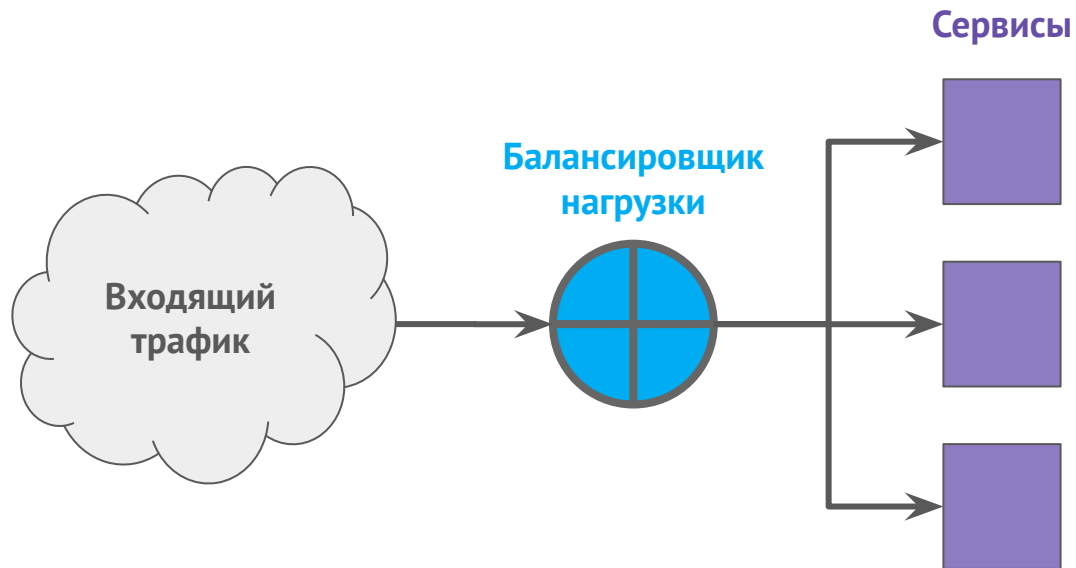
- Максимальное время ожидания (Timeout)
- Повтор запроса (Retry)
- Прерыватели цепи (Circuit Breaker)
- Перегородки (Bulkhead)
- Ограничитель количества запросов (Rate Limiter)
- Изоляция
- Идемпотентность



Балансировка

Балансировщик нагрузки

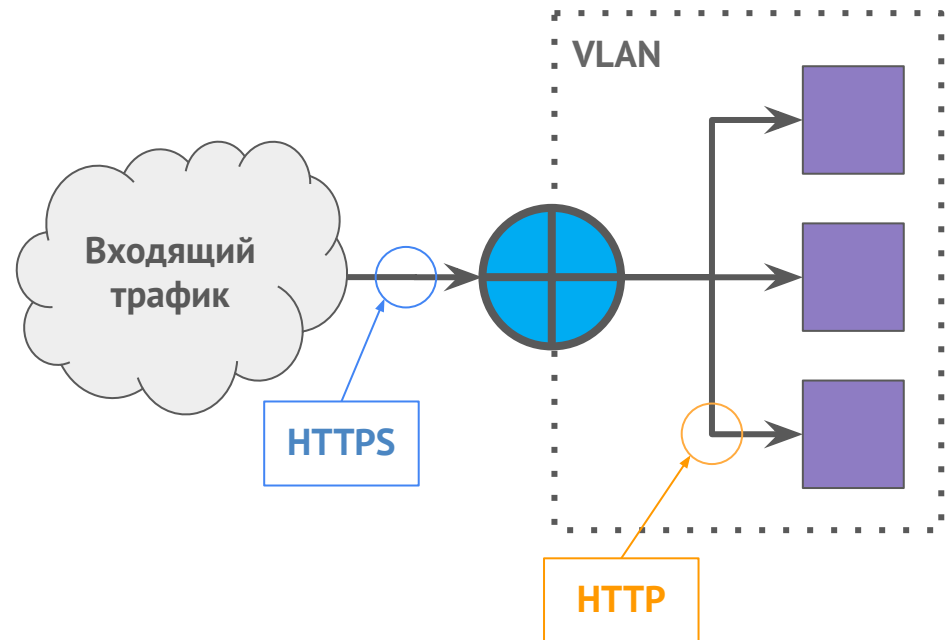
Основная функция: распределение входящих запросов по нескольким серверам



Балансировка

Дополнительные функции

- Терминация SSL
- Активация резервных серверов
- Ассиметричное распределение запросов
- Защита от DDOS атак
- Gzip сжатие HTTP
- Проверка работоспособности
- Кэширование HTTP
- Контентно зависимое распределение запросов
- Аутентификация клиентов
- Фильтрация контента



Балансировщики

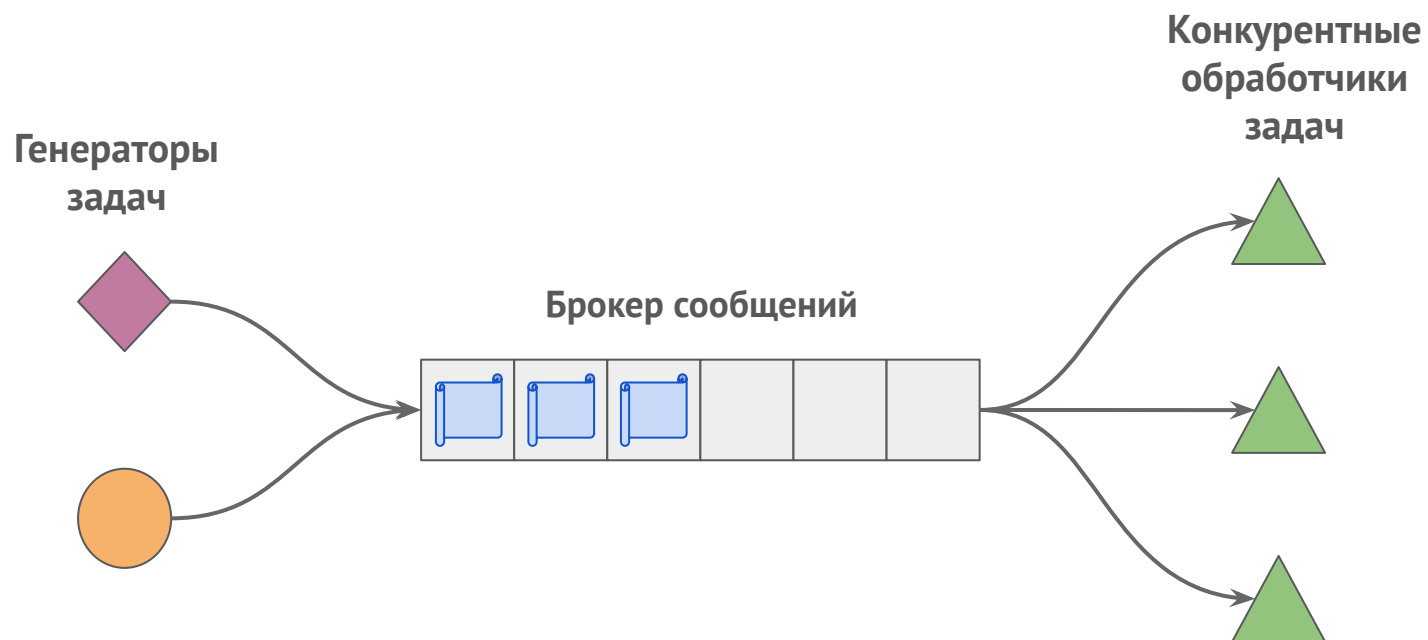
Балансировщики

- Nginx
- F5
- Kemp
- HAProxy
- Envoy

Облачные балансировщики

- AWS Elastic Load Balancer
- Google Cloud Load Balancing
- Azure Load Balancer
- Yandex Cloud Network Load Balancer

Системы обработки задач



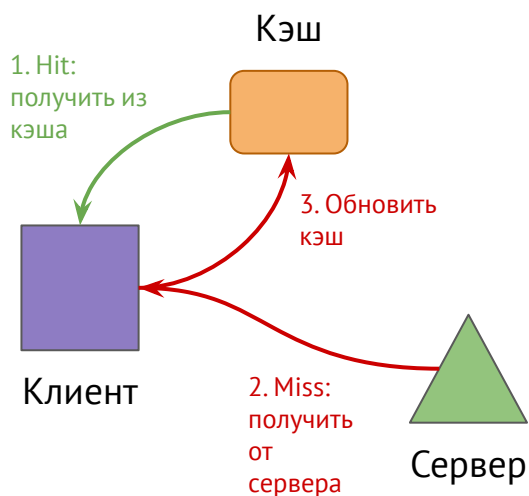


Кэширование

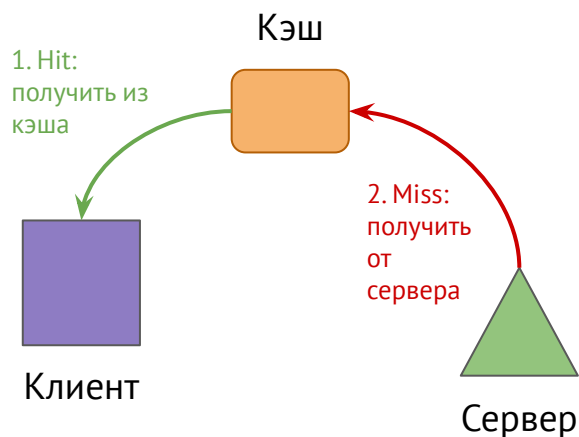
Кэширование

Кэширование - наиболее распространенный способ повышения производительности

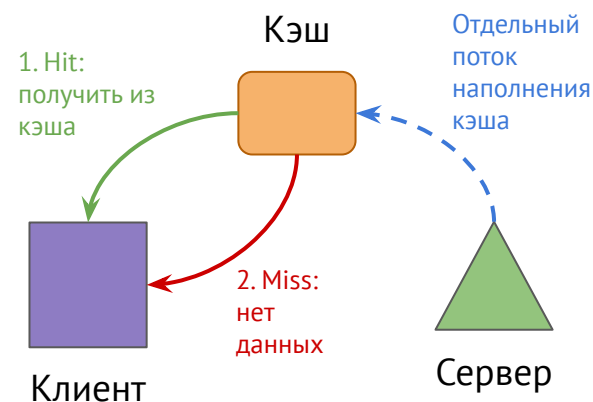
Клиентский кэш



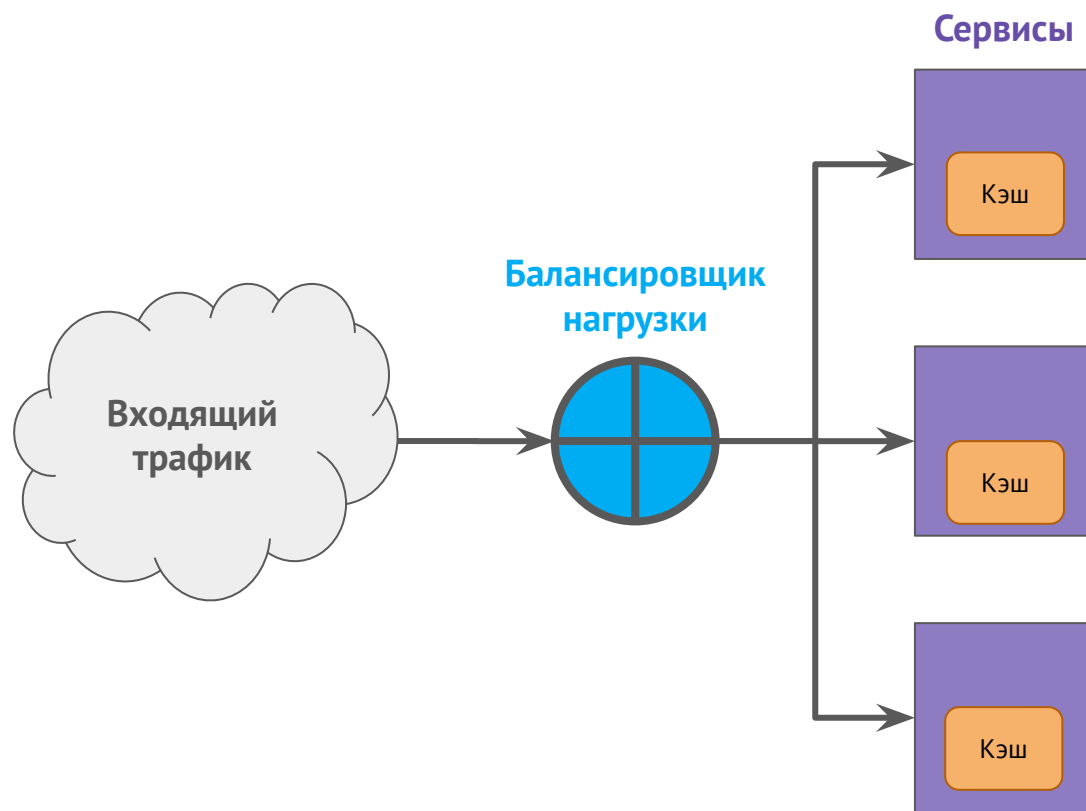
Сквозной кэш



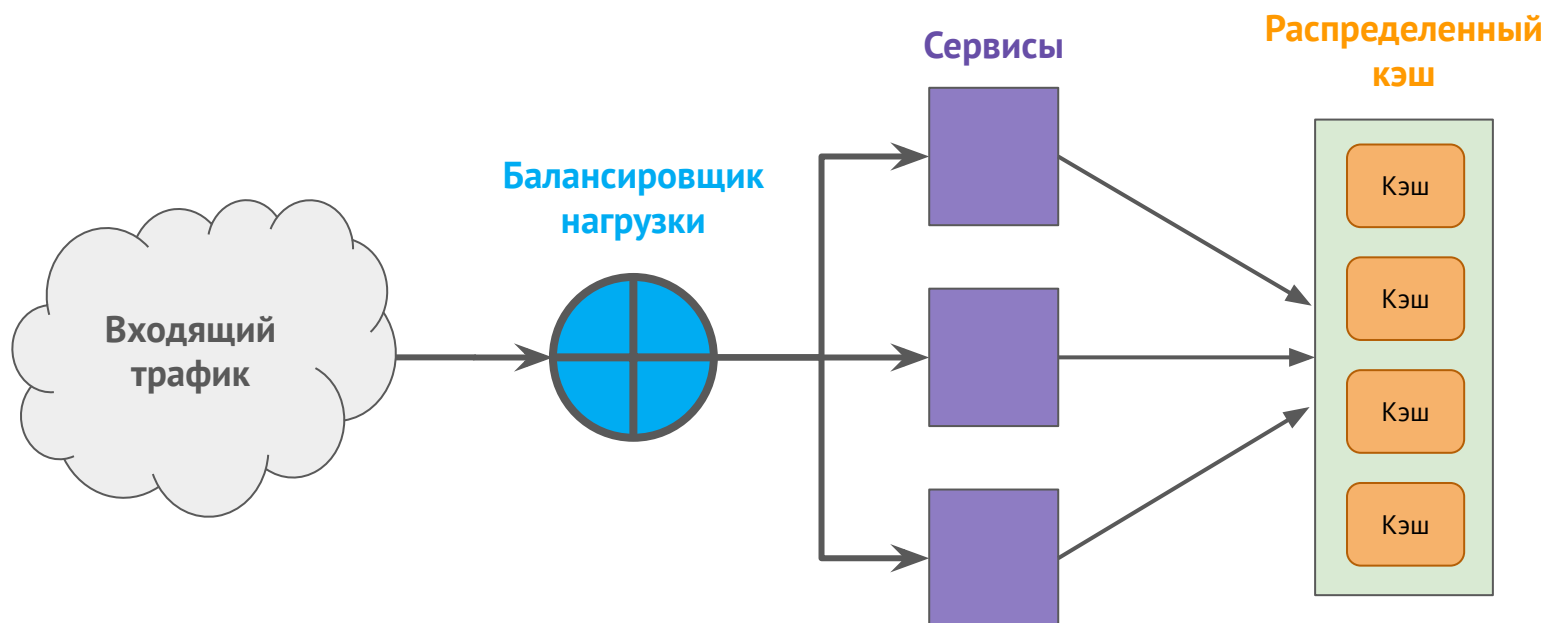
Прогретый кэш



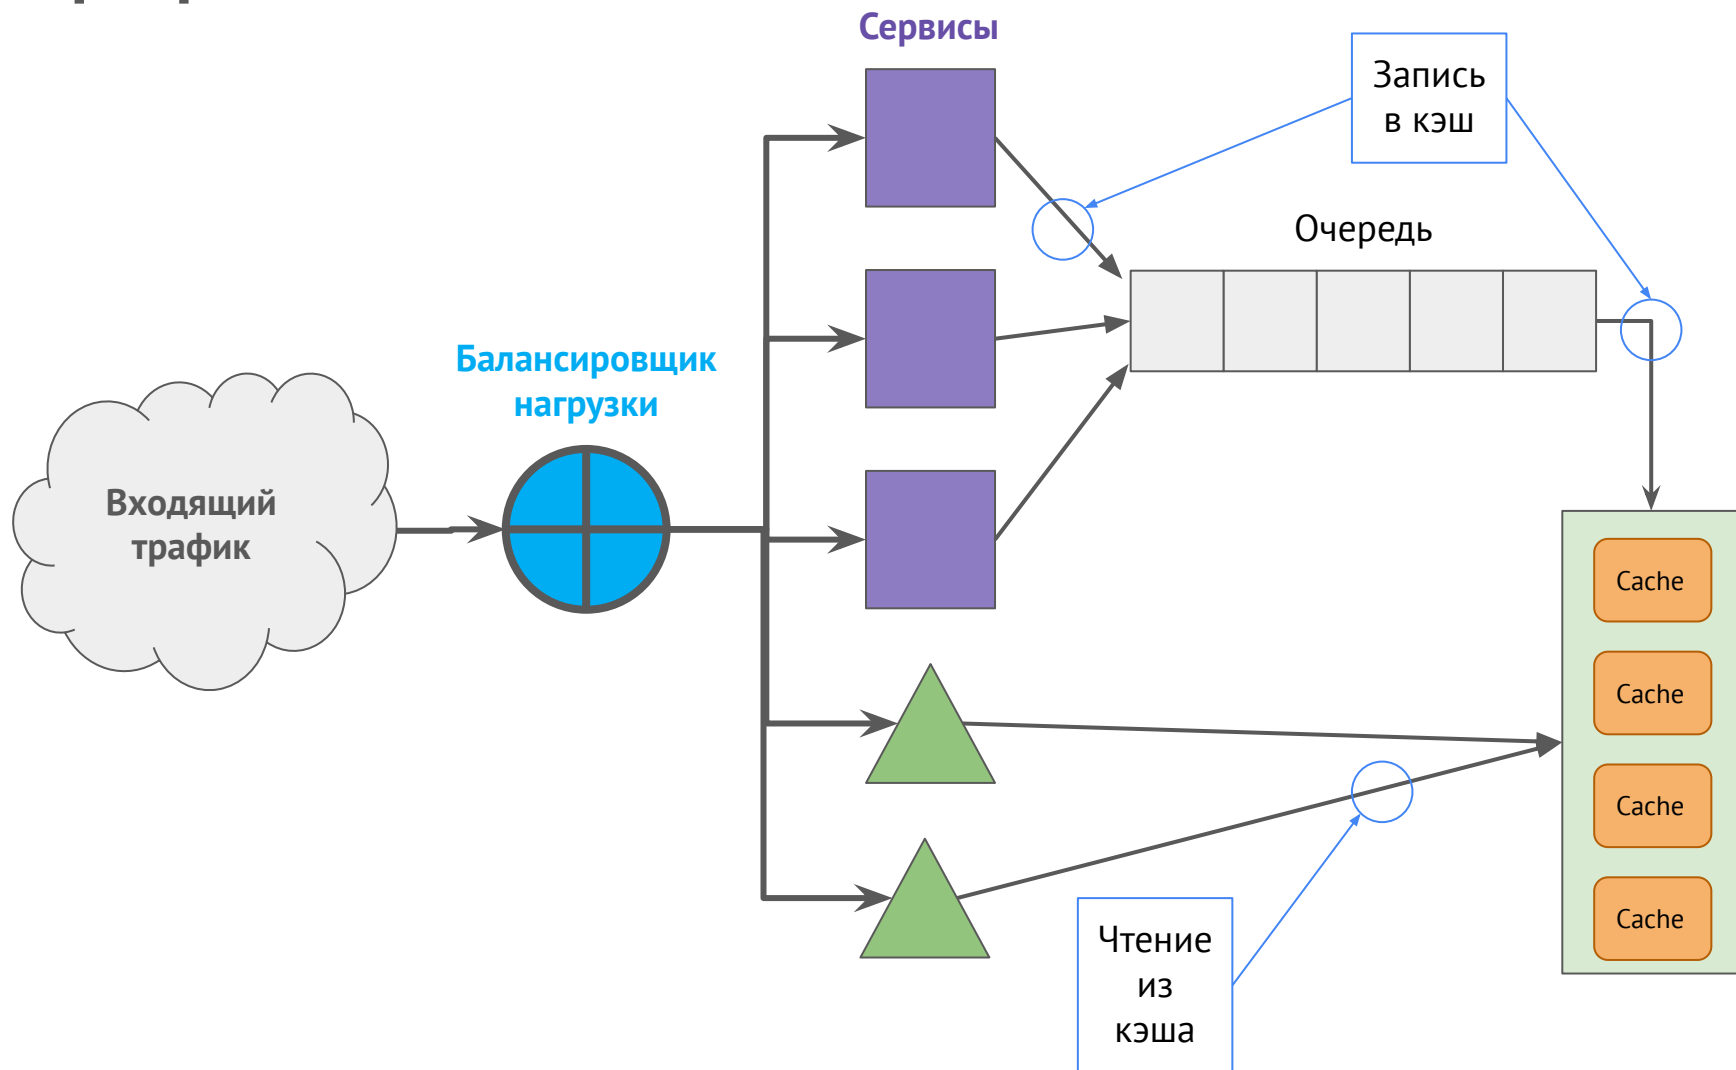
Кэш встроен в сервис



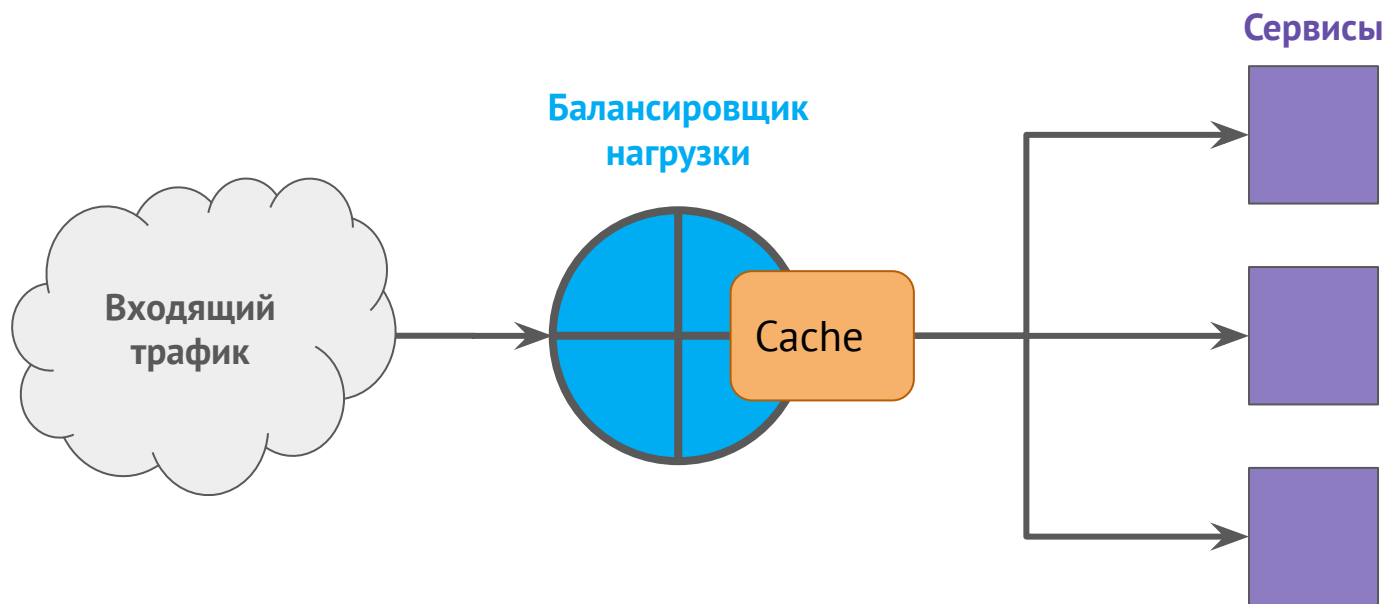
Распределенный кэш



Прогретый кэш



Кэширующий балансировщик



In-Memory Кеш

- Hazelcast
- Redis
- Memcached
- Tarantool



Автомасштабирование

Автоматическое масштабирование

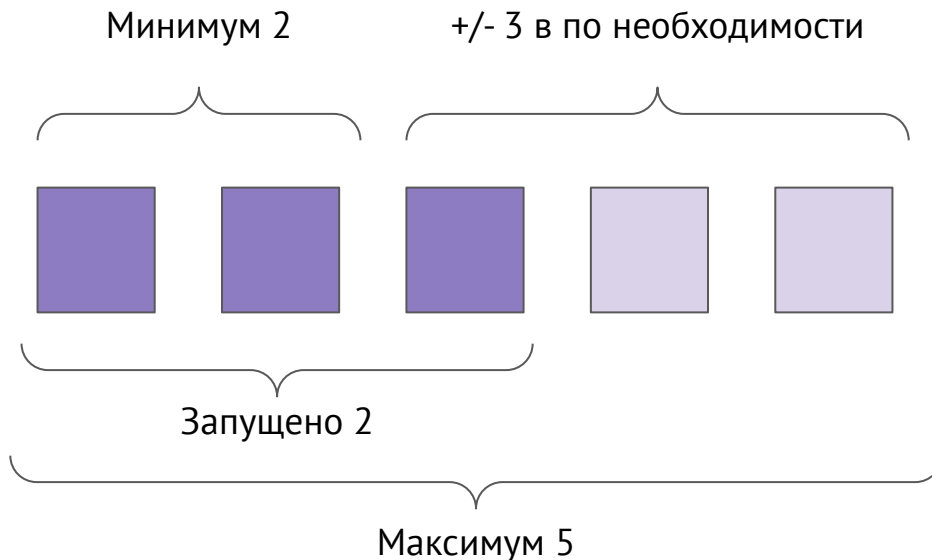
Процесс динамического выделения ресурсов для удовлетворения требований производительности:

При увеличении нагрузки

выделяются дополнительные ресурсы для обеспечения соглашения об уровне обслуживания (SLA)

При снижении нагрузки

освобождаются ресурсы для экономии средств



Необходимые компоненты

- Мониторинг приложений и инфраструктуры
- Логика принятия решений
- Управление ресурсами
- Тестирование процедуры автомасштабирования

Подходы

- Динамическое масштабирование на основе метрик приложения или инфраструктуры:
 - Среднее значение CPU
 - Общее количество запросов
 - Длительность обработки задачи
 - Количество запросов завершившихся ошибкой
- Масштабирование по расписанию
- Предсказательное масштабирование

Автомасштабирование

- Kubernetes Horizontal Pod Autoscaler
- Amazon EC2 Auto Scaling
- Azure Monitor
- Google Compute Engine Autoscaling
- Yandex Cloud Cluster-Autoscaler



Service Discovery



Service Discovery

Настройки

У клиентов в конфигурации IP адреса сервисов с которыми ему нужно взаимодействовать

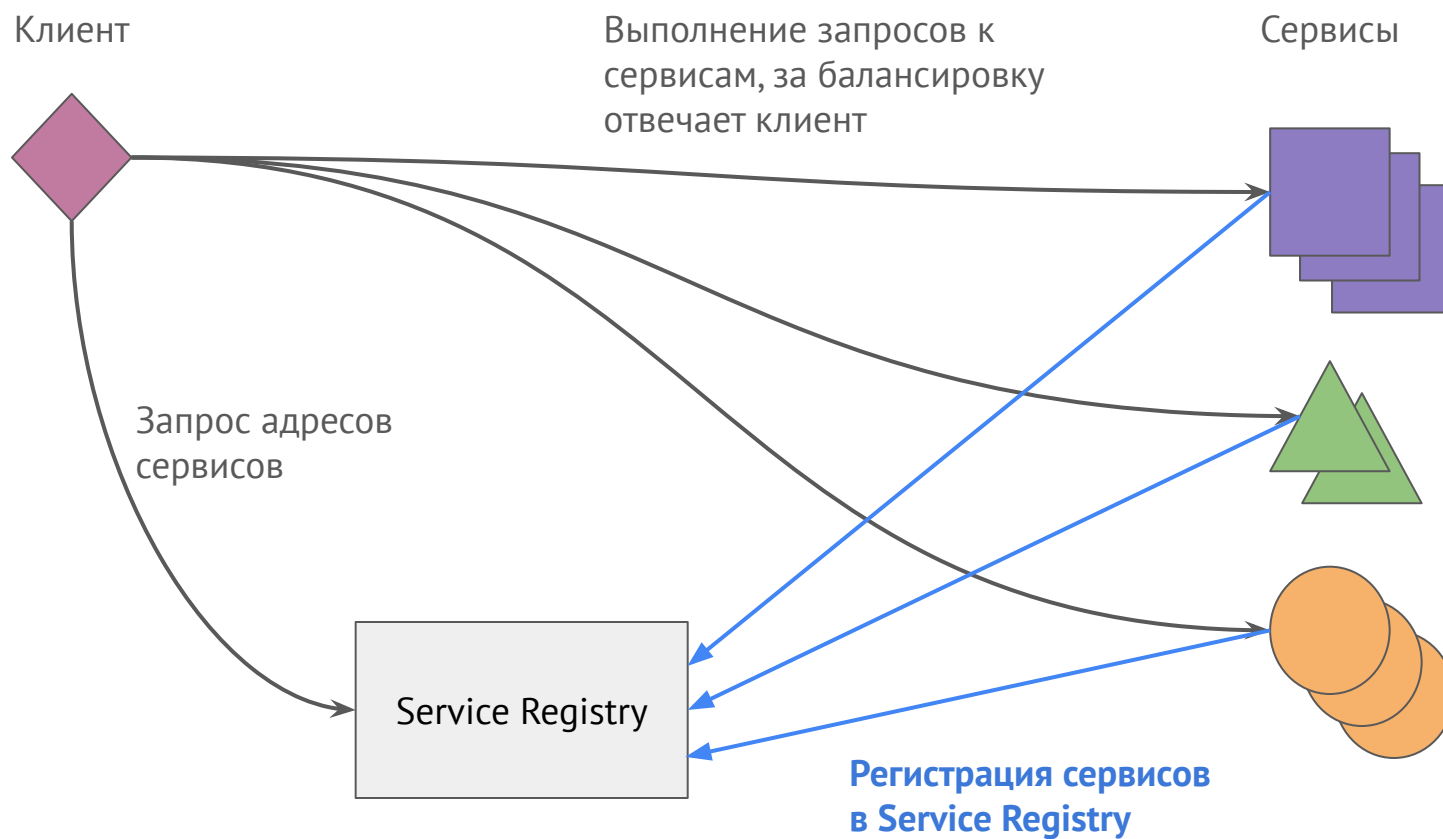
DNS

У каждого сервиса есть DNS имя за которым несколько IP адресов его запущенных экземпляров

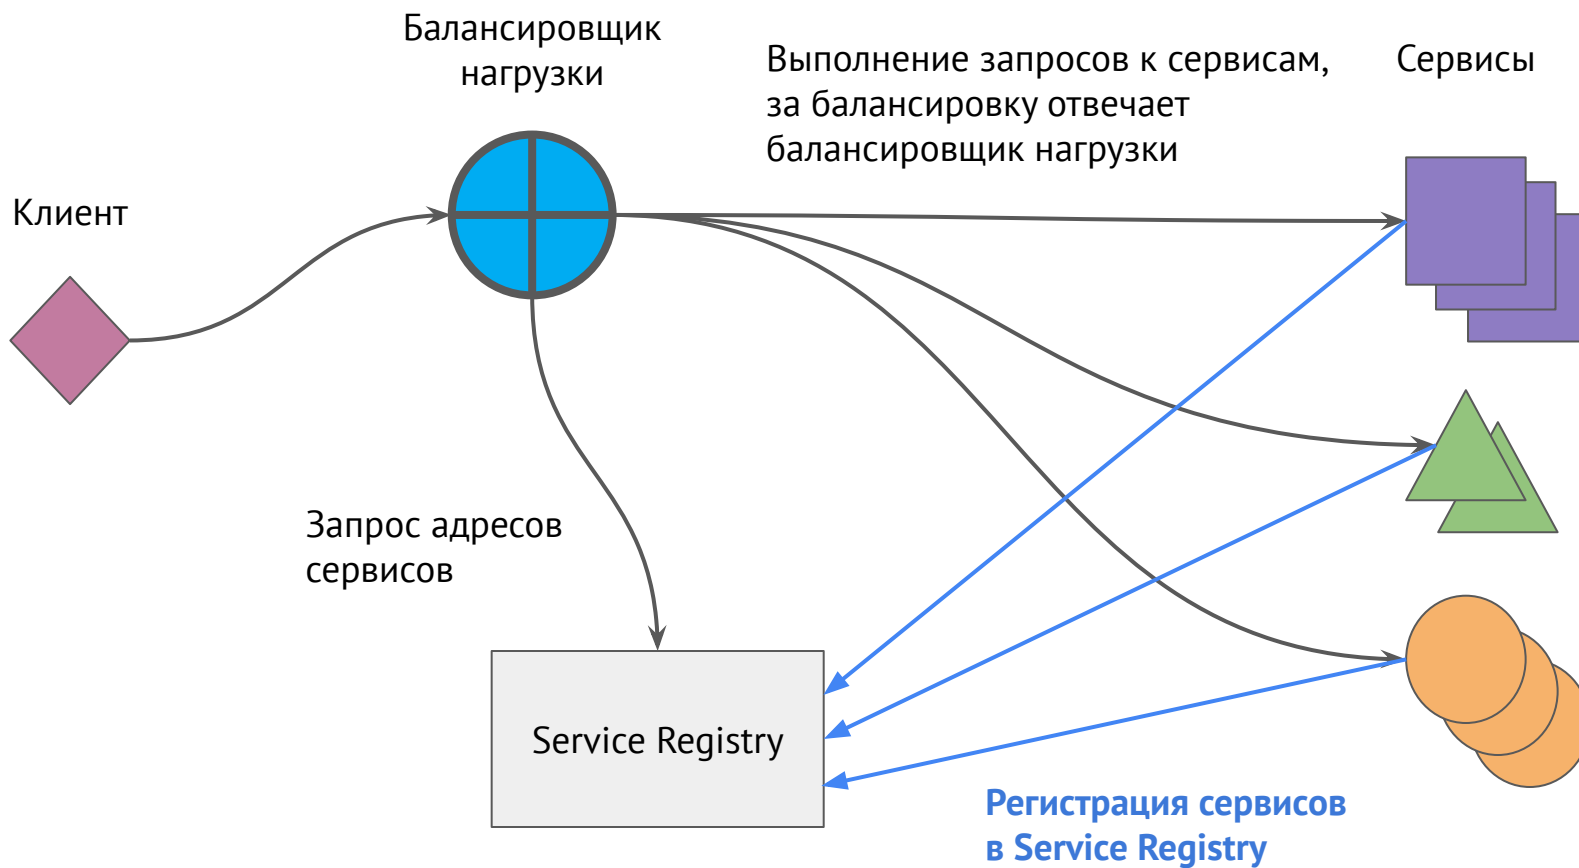
Service Registry

Специальное программное обеспечение позволяет сервисам при старте зарегистрировать адреса запускаемого экземпляра, а клиентам получить эти адреса по имени

Service Registry



Service Registry



Service Registry

- Zookeeper
- Consul
- Eureka
- Самодельный

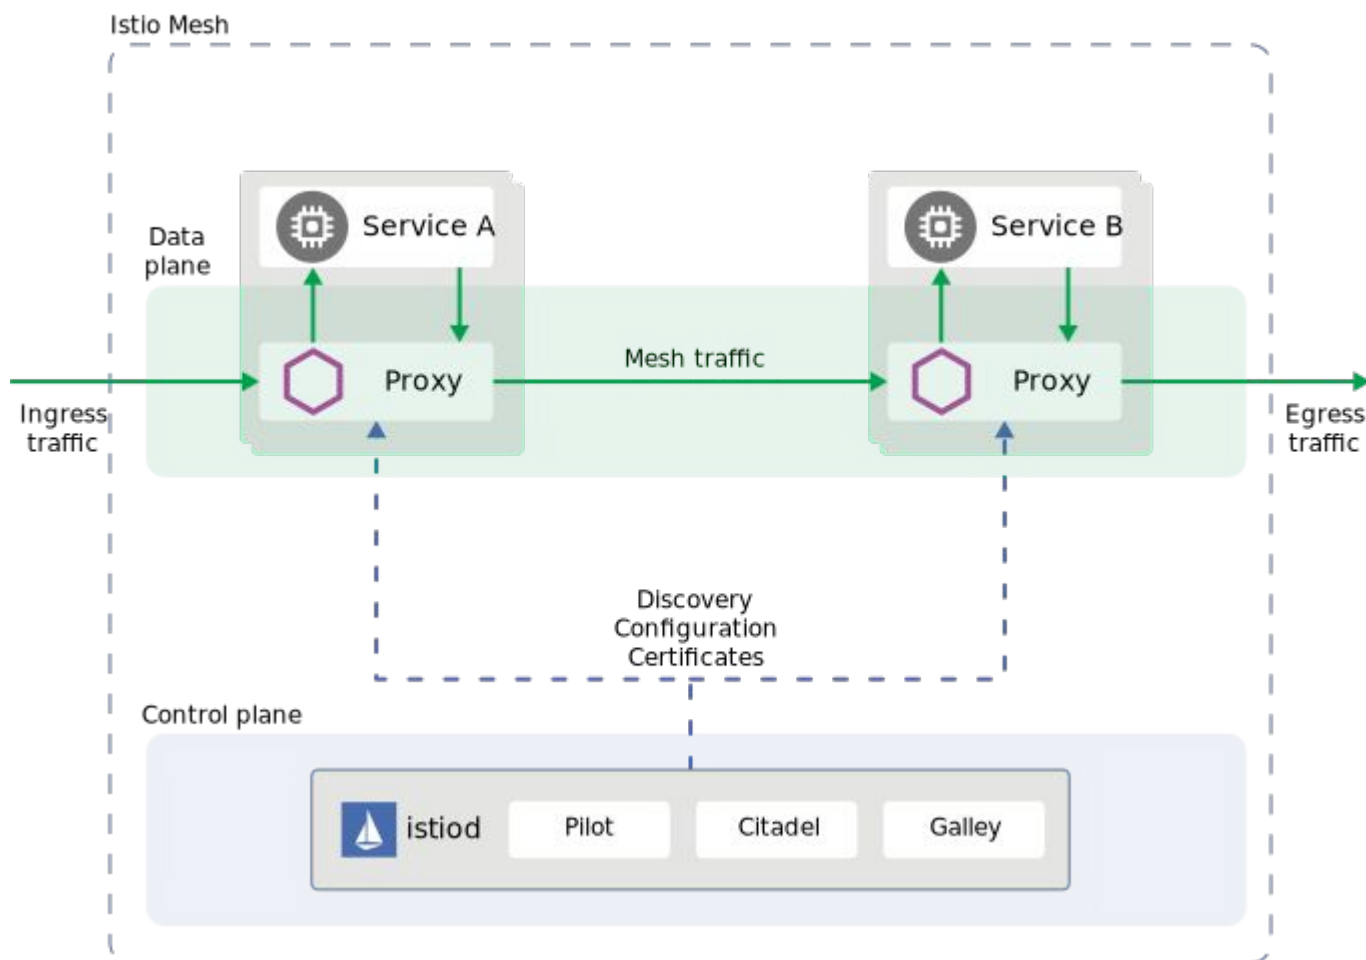


Service Mesh

Задачи Service Mesh

- **Гибкость настройки** взаимодействия сервисов на уровне инфраструктуры, управление трафиком, балансировка
- **Унифицированный мониторинг** большой системы
- **Повышение безопасности:** отсутствие риска перехвата трафика, полный контроль над сетью, исключение угроз при работе в нескольких дата центрах или публичных облаках
- **Упрощение реализации сложных шаблонов развертывания** приложений: Blue/Green, Canary, A/B Testing
- **Организация взаимодействия сервисов в мульти кластерной среде**

Принцип работы Service Mesh на примере Istio



Service Mesh

- Istio
- Linkerd
- Consul Connect
- Kuma
- Maesh
- OpenShift Service Mesh
- AWS App Mesh

Итоги

- Узнали важность непрерывной поставки для микросервисной архитектуры
- Познакомились со способами развертывания микросервисов
- Узнали про разные виды тестирования и изучили влияние пирамиды тестирования на результат
- Разобрали разные способы обеспечения аутентификации и авторизации
- Познакомились со способами мониторинга: метрики, логи, трассировка
- Обсудили масштабирование и кэш



Домашнее задание

Давайте посмотрим ваше [домашнее задание](#).

- Вопросы по домашней работе задавайте **в чате** мессенджера Slack.
- Задачи можно сдавать **по частям**.
- Зачёт по домашней работе проставляется после того, как **приняты все задачи**.

**Задавайте вопросы и
пишите отзыв о лекции!**

Михаил Триполитов

